IUM MACHINE LEARNING CANVAS

Nr tematu: 1 Zespół: MiziaKwasniak Data: 03.05.26 Iteracja: 2 .

ZADANIA MODELOWANIA

Zadanie modelowania to klasyfikacja binarna czy cena jest zawyżona czy też nie. Po wdrożeniu, predykcje generowane są dla obecnych danych ofert w tabeli calendar. Wyniki obserwowane są np. przy klasyfikacji przez zespół nadzorujący czy model wykonał dobrą predykcję. Predykcja będzie odbywała się per oferta-noc, używając listing_id oraz date z tabeli calendar.csv.

DECYZJE

Predykcję o zawyżeniu ceny z prawdopodobieństwem zawyżenia powyżej zadanego progu mogą być przekształcone np. w decyzję o nie rekomendowaniu ogłoszenia i kontakt z oferentem.

PROPOZYCJA WARTOŚCI

Ostatecznym beneficjentem jest użytkownik końcowy który pomija frustrację ze sztucznie zawyżonymi cenami oraz serwis Nocarz który może z tego względu liczyć na lepszy wskaźnik konwersji. System uczenia maszynowego mógłby zostać zintegrowany z systemem rekomendacji żeby zmniejszyć wagę rekomendacji dla ogłoszeń w których przypuszcza się sztuczne zawyżenie ceny. Uczciwy oferent może liczyć na lepsze pozycjonowanie swoich ofert ze względu na usunięcie ofert nieuczciwych.

ZBIERANIE DANYCH

Po wdrożeniu, można pobierać codzienny snapshot cen i dostępności w celu późniejszego dostrajania modelu do potencjalnego dryfu wartości na których model polega.

ŹRÓDŁA DANYCH

Do skonstruowania wstępnego zbioru danych uczących będą potrzebne dane z tabeli calendar oraz listings czyli dane zmian ceny wynajmu dla konkretnego lokalu oraz dane na temat cech i położenia lokalu.

Naturalnie pasuje tu binarna etykieta której wartość 1 oznacza zawyżenie ceny a wartość 0 brak zawyżenia. Zostanie ona stworzona na podstawie progu x odchyleń standardowych powyżej średniej ceny w regionie i n odchyleń powyżej historycznej ceny danego lokalu, gdzie x i n zostaną dobrane iteracyjnie ze zleceniodawcą.

WPŁYW PROJEKTU

Możliwe błędy to: uczciwa oferta błędnie oznaczona lub manipulacja niewykryta. Koszt nie wykrycia manipulacji jest subiektywnie niższy ponieważ jest zbieżny z obecnym działaniem serwisu jednak koszt fałszywego oznaczenia uczciwej oferty jest większy ponieważ może prowadzić do złego doświadczenia oferenta i opuszczenia platformy na rzecz innych. Do symulacji wpływu przed wdrożeniem można użyć np. ilości manipulacji które model poprawie wykryłby w ciągu ostatnich 6 miesięcy. Kryterium sukcesu to np. wykrycie powyżej 90% manipulacji przy współczynniku fałszywego oznaczenia uczciwej oferty poniżej 2%.

GENEROWANIE PREDYKCJI

Tryb batch raz dziennie dla całego kalendarza. Dodatkowo real-time przy każdej zmianie ceny przez oferenta z czasem poniżej 1 sekundy.

BUDOWANIE MODELI

2 modele do testów A/B.
Modele będą dotrenowywane nowymi danymi co miesiąc a ich skuteczność będzie testowana za pomocą testów A/B.
Czas przeznaczony na wyznaczanie atrybutów, analizę i trenowanie to 10h.
Bazowy model to prosta heurystyka progowa, a docelowy to klasyfikator XGBoost.

ATRYBUTY

Główne encje wykorzystywane do generowania predykcji to listing_id (pozwala agregować ze sobą informacje o oferta z zbioru listings.csv oraz calendar.csv), price (z calendar.csv oraz listing.csv) na którym stosowana jest transformacja pozwalająca na przekształcenie '$1,100.00' do wartości liczbowej, date (z calendar.csv) pozwalające na analizę zmian cen noclegów w czasie, encje 'available' (z calendar.csv) i 'neighbourhood_group_cleansed' pozwalające (po agregacji danych z listings i calendar) na analizę dostępności ofert zależnie od dzielnicy. Na podstawie średniej wartości kolumny price, zostanie wygenerowana kolumna określająca czy cena jest zawyżona.

MONITOROWANIE

Metryki modelu to precision, recall, F1. A metryki biznesowe to np. conversion rate wyszukiwań oraz ilość skarg oferentów. Powinny być przeglądane w review tygodniowym (częściej niż dotrenowanie modeli). Alerty jeśli model docelowy spadnie o 5 punktów F1 względem baselinu oraz jeśli ilość tygodniowych skarg wzrośnie dwukrotnie.

Dokument jest utworzony na podstawie: OWNML MACHINE LEARNING CANVAS v 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.