IUM – Dokumentacja

Przygotowanie modeli + serwisu z testem A/B

Jakub Kwaśniak, Michał Mizia

1. Zadanie:

“Czasami oferenci zawyżają ceny, aby nikt w danym okresie nie rezerwował u nich noclegów – jakoś musimy to wykrywać, żeby dało się odpowiednio reagować.”

2. Kontekst

W ramach projektu wcielamy się w rolę analityka pracującego dla portalu Nocarz – serwisu, w którym klienci mogą wyszukać i dokonać rezerwacji noclegu (zapewnianego przez oferentów). Praca na tym stanowisku nie jest łatwa – zadanie dostajemy w formie enigmatycznego opisu i to do nas należy doprecyzowanie szczegółów tak, aby dało się je zrealizować. To oczywiście wymaga zrozumienia problemu, przeanalizowania danych, czasami negocjacji z szefostwem. Poza tym, oprócz przeanalizowania zagadnienia i wytrenowania modeli, musimy przygotować je do wdrożenia produkcyjnego –zakładając, że w przyszłości będą pojawiać się kolejne ich wersje, z którymi będziemy eksperymentować.

Jak każda szanująca się firma internetowa, Nocarz zbiera dane dotyczące swojej działalności – są to (analitycy mogą wnioskować o dostęp do tych informacji na potrzeby realizacji zadania):

- szczegółowe dane o dostępnych lokalach,
- recenzje lokali,
- kalendarz z dostępnością i cenami,
- baza klientów i sesji.

3. Analityczne kryterium sukcesu – założone zostało:

Wykrycie powyżej 90% manipulacji przy współczynniku fałszywego oznaczenia uczciwej oferty poniżej 2%.

4. Zadanie modelowania:

Wg pierwotnych założeń zaimplementowane zostały 2 modele klasyfikacyjne – potrafiące oznaczać nowe oferty jako te z prawidłową ceną oraz takie z ceną zawyżoną. W tym celu stworzyliśmy heurystykę zakładającą że jako oferty o cenie zawyżonej można oznaczyć lokale, których cena w danym dniu jest większa niż

‘średnia + 0.5 * odchylenie’

cen lokali tego samego typu, w tej samej okolicy w ciągu bieżącego miesiąca

Tak oznaczone dane posłużyły jako zbiór treningowy i testowy dla 2 modeli bazowego – regresji logistycznej oraz zaawansowanego – o ile analitycze kryterium sukcesu na zbiorze testowym zostało spełnione, to model bazowy osiągał lepsze wyniki predykcji niż model zaawansowany. Doprowadziło nas to do wniosku, iż prawdopodobnie model regresji idealnie wyucza się naszej liniowej heurystyki.

Skutkowało to w zmianie zadanie modelowania z klasyfikacji na regresję:

- Modele potrafią na podstawie okreslonych atrybutów nowej oferty, przewidzieć odpowiednią ‘uczciwą’ cenę oferty (Cena podana w ofercie nie jest wykorzystywana podczas analizy)
- Jeśli cena podana w ofercie jest ‘n’ (w naszym serwisie n=2) razy większa niż cena przewidziana przez regresor jako prawidłowa, wówczas oferta jest uznawana jako odstająca – o sztucznie zawyżonej cenie.
- Dzięki temu podejściu nie musimy wyuczać nowego modelu np. przy zmianie progu zawyżenia ceny. Dodatkowo, ustawiając próg możemy kontrolować czułość algorytmu, przez co zmieniać stosunek fałszywych pozytywów do fałszywych negatywów aby dynamicznie spełnić kryterium sukcesu w zależności od zebranych danych.

5. Przygtowane modele:
    - Bazowy: regresja liniowa
    - Zaawansowany: XGBoost (o eksperymentalnie dobranych parametrach)

    Do wyuczenia modeli przewidywania ceny, jako cel predykcji została użyta nie cena, a logarytm ceny, w ten sposób zmniejszyliśmy wpływ wartości odstających (ang. outliers) w zbiorze treningowym na trening modelu

    Dane z users.csv, reviews.csv w przeprowadzonych analizach (EDA dostępne w repozytorium) wykazują niską informatywność i prawdopodobnie nie wniosą wysokiej wartości do predykcji przygotowanych modeli – dane o użytkownikach, np. skąd pochodzą nie wykazały wpływu na np. rezerwacje ofert; natomiast dane z reviews mogą nie być pomocne przy przygotowaniu modelu wykrywającego anomalie w nowych ofertach (które nie mają jeszcze opinii/ocen)

    Główne analizy i przygotowane modele zostaną oparte o dane z calendar.csv oraz listings.csv – wykorzystane atrybuty:

    Calendar:
    - Listing_id
    - Date
    - Price

    Listings:
    - Neighbourhood_group_cleansed
    - Property_type
    - Room_type
    - Accomodates
    - Bathroms
    - Bedrooms
    - Beds

    Dobór takich cech wynika z analizy dostarczonych próbek danych (EDA) znajdujących się w repozytorium jako notebook’i w notebooks/data_v{n}_analysis.ipynb (gdzie n to numer kolejnych próbek danych)

    Najpierw przygotowany został wstępny ‘preprocessing’ wybranych danych – np. zmiana pola daty na składowe dzień, miesiąc, rok, kwartał; formatowanie danych do właśiwej postaci jak zmiana ${price} na wartość liczbową czy usunięcie pól z brakującymi wartościami ‘listing_id’ kolumną kluczową do określenia zależności miedzy tabelami I wybrania atrybutów dla danej oferty

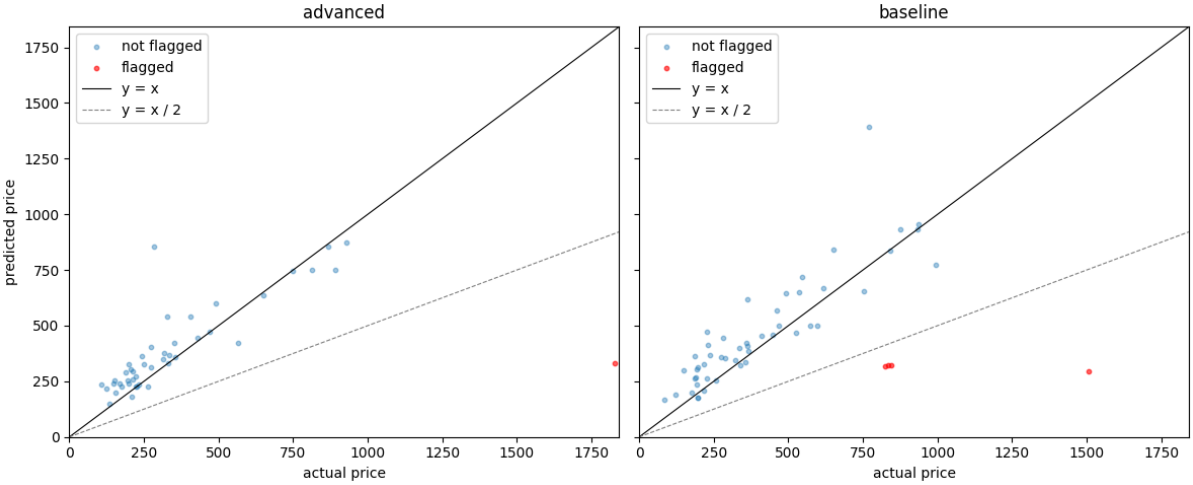
    Następnie do treningu oraz ewaluacji modelu przygotowany został pipeline:
    - imputujący brakujące dane numeryczne najczęstsze (“most_frequent”) oraz dane kategoryczne stałą “Unknown”
    - skaler – skalujący dane numeryczne

- koder – do zakodowania danych kategorycznych, zważywszy na małą liczbę kategorii, użyto one hot encoding

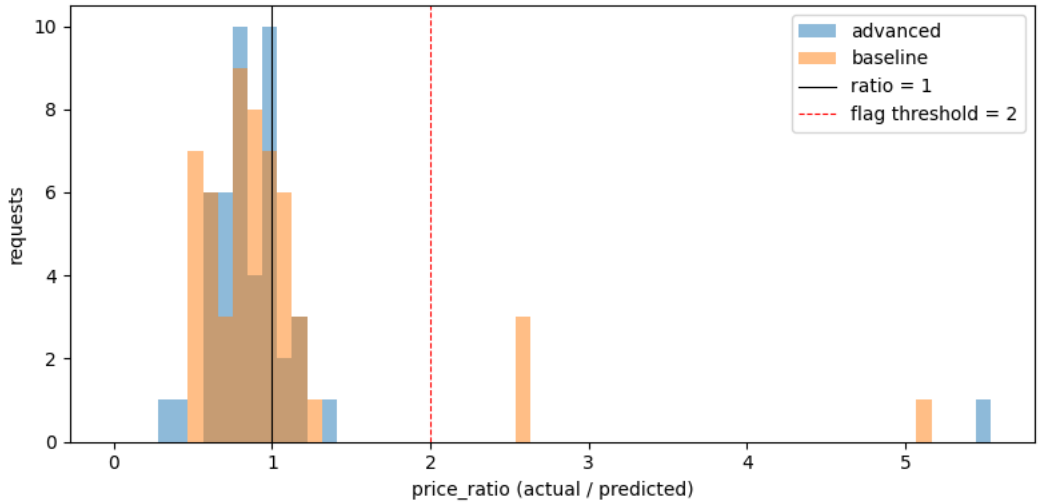
(Testowane było również wykorzystanie Multi-hot encoder do zakodowania zmiennej “amenities” składającej się z listy stałych wartości kategorycznych, jednkaże wykorzystanie atrybutu pogorszyło wyniki, dlatego został wyrzucony z wybranych atrybutów)

6. Porównanie modeli – bazowy i zaawansowany

Na poniższych wykresach, widzimy po lewej stronie predykcję wykonane modelem xgboost regression, a po prawej modelem regresji liniowej. Na osi pionowej widzimy cenę przewidywaną, a na poziomej cenę wystawioną. Linia kropkowana oznacza próg, gdzie cena wystawiona jest dwa razy wyższa niż przewidywana. Oba modele dosyć dobrze przewidują ceny dla większości ofert w okolicach y=x.



Na dystrybucji price_ratio czyli ceny wystawionej do ceny przewidywanej widzimy zachowanie które mocno wskazuje na faktyczne zawyżanie cen. Model dosyć dobrze przewiduję rzeczywistą dystrybucję cen o czym świadczy rozkład normalny price_ratio skupiony w okolicy wartości 1, jednak rozkład ten ma nietypowy ogon po prawej stronie co może sugerować nienaturalne pochodzenie tamtych zjawisk. Wykres został wykonany dla 100 przykładowych ofert z wydzielonego zbioru testowego.



7. Serwis + Eksperyment A/B

Serwis umożliwia uruchomienie generowania predykcji na nowej ofercie, gdzie model przydzielany jest losowo (bazowy lub zaawansowany) – wynikiem zapytania jest predykcja czy cena oferty jest zawyżona oraz kilka statystyk związanych z ceną oferty. Wynik działania modelu wraz z metadanymi wywołania jest również zapisywany do pliku ‘data/prediction.log’.

Przykładowy log oraz eksperymenty / analizy przeprowadzona na danych z zbieranego loga, dostępne są w notebooku notebooks/ab_test.ipynb

Statysyka dla obu modeli z przeprowadzonego testu:

model	requests	share	flag_rate	median_actual	median_predicted	median_ratio	mae_price	std_predicted	std_ratio
advanced	45	0.45	0.022222	262.06	326.277530	0.837896	106.989677	198.016257	0.726987
baseline	55	0.55	0.090909	362.35	398.323633	0.879096	201.053464	314.176166	1.035419

Z tych statystyk, widać że model zaawansowany ma prawie dwa razy mniejszy błąd bezwględny w przewidywaniu ceny od modelu bazowego. Oba modele dla mediany przewidują ceny około 15% wyższe niż ceny rzeczywiste co może wynikać z faktu że w zbiorze treningowym nie zostały odrzucone oferty zawyżone, a mimo użycia log-price zamiast surowej ceny, model i tak musiał wziąć pod uwagę ich sygnał. Widzimy również że dewiacja standardowa modelu zaawansowanego jest znacznie niższa od dewiacji modelu bazowego, co świadczy o bardziej rozrzuconych przewidywaniach modelu bazowego, i potencjalnie o większej ilości fałszywych pozytywów.